

ỦY BAN NHÂN DÂN TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO CUỐI KỲ

ĐỀ TÀI:
DỰ ĐOÁN BỆNH RỐI LOẠN GIÁC NGỦ

Bộ môn: Khai Phá Dữ Liệu

Giảng viên: ThS. Nguyễn Thanh Phước

Sinh viên thực hiện
Huỳnh Quang Quân 3122410341

Tp.HCM, Ngày 24 Tháng 05 Năm 2025

LỜI CẢM ƠN

Lời đầu tiên chúng em xin chân thành cảm ơn các thầy cô trong khoa Công nghệ thông tin của trường Đại học Sài Gòn, những người đã trực tiếp giảng dạy, cung cấp kiến thức và phương pháp trong những năm học qua. Đó là những nền tảng cơ bản, là hành trang vô cùng quý giá để chúng em có thể bước vào sự nghiệp tương lai. Để có được kết quả này, chúng em xin đặc biệt gửi lời cảm ơn chân thành tới **thầy Nguyễn Thanh Phước** đã quan tâm giúp đỡ, vạch kế hoạch và hướng dẫn chúng em hoàn thành một cách tốt nhất đồ án trong thời gian qua. Cuối cùng, chúng em xin chân thành cảm ơn mọi người đã chia sẻ, giúp đỡ và đóng góp nhiều ý kiến quý báu để chúng em có thể hoàn thành đồ án môn học này. Trong quá trình hoàn thành đồ án, vì chưa có nhiều kinh nghiệm thực tế và chủ yếu dựa trên lý thuyết đã học nên chắc chắn không tránh khỏi những thiếu sót. Kính mong nhận được sự góp ý, nhận xét từ các thầy cô để kiến thức của chúng em ngày càng hoàn thiện hơn và có thể rút ra nhiều kinh nghiệm bổ ích, áp dụng vào thực tiễn một cách hiệu quả trong tương lai.

[illegible]

(Ký tên và ghi rõ họ tên)

MỤC LỤC

Chương 1: GIỚI THIỆU	1
1.1 Bối cảnh của bài toán	1
1.2 Định nghĩa bài toán	2
1.3 Các giải pháp để giải quyết bài toán	3
1.4 Vai trò của khai phá dữ liệu trong việc giải quyết bài toán trên	4
1.5 Kết quả dự đoán sau khi giải quyết bài toán trên	4
Chương 2: MÔ TẢ DỮ LIỆU	6
2.1 Kích thước dữ liệu, chiều dữ liệu, trích dẫn nguồn dữ liệu	6
2.2 Các kiểu dữ liệu	6
2.3 Thống kê mô tả về dữ liệu	9
2.4 Những giả thiết khi thu thập dữ liệu	15
Chương 3: PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU	16
3.1 Quy trình khai phá dữ liệu	16
3.2. Nguyên lý hoạt động của mô hình/thuật toán	18
3.3. Cách cài đặt mô hình	21
3.4. Tiêu chí đánh giá mô hình	23
Chương 4: THỰC NGHIỆM	25
4.1. Yêu cầu về chương trình	25
4.2 Thực hiện khai phá dữ liệu	26
4.3. Code	29

Chương 5: KẾT QUẢ	32
5.1 Kết quả khai phá dữ liệu	32
5.2 So sánh kết quả thực tế với kết quả dự đoán	34
Chương 6: THẢO LUẬN VÀ KẾT LUẬN	36
6.1 Khả năng ứng dụng của giải pháp/mô hình	36
6.2 Ưu điểm – Nhược điểm của giải pháp/mô hình	36
6.3 Đề xuất	37
TÀI LIỆU THAM KHẢO	39

MỤC LỤC BẢNG

Bảng 2.1 Bảng mô tả các thuộc tính dữ liệu	7
Bảng 4.1 Thư viện sử dụng	25
Bảng 6.1 Bảng ưu điểm & Nhược điểm của giải pháp mô hình	37

MỤC LỤC HÌNH

Hình 2.1 Thống kê số phút bệnh nhân hoạt động thể chất mỗi ngày	9
Hình 2.2 Thống kê mức độ căng thẳng của bệnh nhân	9
Hình 2.3 Thống kê tuổi của bệnh nhân	10
Hình 2.4 Thống kê số giờ bệnh nhân ngủ mỗi ngày	10
Hình 2.5 Thống kê nhịp tim của bệnh nhân	11
Hình 2.6 Thống kê số bước chân bệnh nhân đi mỗi ngày	11
Hình 2.7 Thống kê huyết áp tâm thu của bệnh nhân	12
Hình 2.8 Thống kê huyết áp tâm trương của bệnh nhân	12
Hình 2.9 Thống kê bệnh nhân mắc bệnh rối loạn giấc ngủ (dương tính)	13
Hình 2.10 Thống kê chỉ số BMI của bệnh nhân	13
Hình 2.11 Thống kê giới tính của bệnh nhân	14
Hình 2.12 Thống kê nghề nghiệp của bệnh nhân	14
Hình 4.1 Đọc dữ liệu gốc và tách thuộc tính Blood Pressure	29
Hình 4.2 Xử lý ngữ cảnh và chia dữ liệu	29
Hình 4.3 Xử lý giá trị	29
Hình 4.4 + 4.5 Xử lý đặc trưng/ thuộc tính	30
Hình 4.6 Mã hóa đặc trưng categorical	30
Hình 4.7 Mã hóa nhãn	31
Hình 4.8 Cân bằng lớp SMOTE	31
Hình 4.9 Tạo mô hình và huấn luyện	31
Hình 5.1 + 5.2 Dự đoán (Predicted) so với nhãn thực tế (Actual) Random Forest vs SVM	34

Chương 1: GIỚI THIỆU

1.1 Bối cảnh của bài toán

Giấc ngủ đóng vai trò vô cùng quan trọng đối với sức khỏe thể chất và tinh thần của con người. Theo Tổ chức Y tế Thế giới (WHO), giấc ngủ chất lượng không chỉ giúp cơ thể phục hồi sau một ngày làm việc mệt mỏi mà còn có vai trò duy trì sự cân bằng nội tiết, hỗ trợ trí nhớ, khả năng học tập, và điều tiết cảm xúc. Tuy nhiên, trong nhịp sống hiện đại, nhiều yếu tố như căng thẳng công việc, lối sống ít vận động, chế độ ăn uống thiếu khoa học, hay thậm chí thói quen sử dụng thiết bị điện tử trước khi ngủ đã ảnh hưởng tiêu cực đến chất lượng giấc ngủ.

Tình trạng rối loạn giấc ngủ đang ngày càng trở nên phổ biến trên toàn cầu, đặc biệt là ở những người trưởng thành và người làm việc trong môi trường áp lực cao. Rối loạn giấc ngủ không chỉ khiến con người cảm thấy mệt mỏi, thiếu tập trung mà còn là nguyên nhân tiềm ẩn dẫn đến các bệnh mãn tính như béo phì, tiểu đường, bệnh tim mạch và rối loạn tâm lý. Trong bối cảnh đó, việc khai thác dữ liệu liên quan đến sức khỏe và lối sống để phát hiện và phân tích mối quan hệ giữa các yếu tố ảnh hưởng đến giấc ngủ là một hướng nghiên cứu có ý nghĩa thực tiễn cao.

Dữ liệu được sử dụng trong nghiên cứu này bao gồm các thông tin về nhân khẩu học (tuổi, giới tính, nghề nghiệp), hành vi sống (thời gian ngủ, số bước đi hàng ngày, mức độ hoạt động thể chất), chỉ số sinh lý (nhịp tim, huyết áp, BMI) và các yếu tố tâm lý (mức độ căng thẳng). Từ đó, ta có thể áp dụng các kỹ thuật phân tích và học máy để đánh giá chất lượng giấc ngủ và phát hiện sớm nguy cơ rối loạn giấc ngủ như mất ngủ (*insomnia*) hoặc ngưng thở khi ngủ (*sleep apnea*).

1.2 Định nghĩa bài toán

Bài toán đặt ra là xây dựng một mô hình học máy có khả năng **dự đoán tình trạng rối loạn giấc ngủ** của một cá nhân dựa trên các đặc trưng liên quan đến sức khỏe và lối sống. Mục tiêu cuối cùng là **phân loại tình trạng giấc ngủ** của một người thành một trong ba nhóm.

Dữ liệu đầu vào là một bảng gồm **13 cột (features)** và **374 dòng (mỗi dòng là một cá nhân)**. Các đặc trưng bao gồm:

◆ Thông tin cá nhân:

Person ID: Số ID

Gender: Giới tính (Nam/Nữ)

Age: Tuổi

Occupation: Nghề nghiệp

◆ Lối sống và hoạt động:

Sleep Duration: Số giờ ngủ trung bình mỗi đêm

Physical Activity Level: Mức độ hoạt động thể chất (30–90)

Daily Steps: Số bước đi trung bình mỗi ngày

◆ Chỉ số sinh lý:

Heart Rate: Nhịp tim

Blood Pressure: Huyết áp (chuỗi tâm thu/tâm trương)

BMI Category: Phân loại BMI (Underweight, Normal, Overweight, Obese)

◆ Tâm lý và chất lượng giấc ngủ:

Stress Level: Mức độ căng thẳng (1–10)

Quality of Sleep: Điểm đánh giá chất lượng giấc ngủ (1–10)

- ◆ Sleep Disorder: Nhấn đầu ra, biểu thị tình trạng rối loạn giấc ngủ của từng cá nhân. Đây là một biến phân loại đa lớp (**multi-class classification**) với 3 giá trị:
 - "None"
 - "Insomnia"
 - "Sleep Apnea"

Thuật toán học máy áp dụng là:

- **Random Forest:** Mô hình cây quyết định ngẫu nhiên với nhiều cây con (ensemble)
- **Support Vector Machine (SVM):** Mô hình phân loại tối ưu biên giữa các lớp

1.3 Các giải pháp để giải quyết bài toán

Phân tích dữ liệu khám phá (EDA)

- Phân tích phân phối các biến liên tục như Age, Sleep Duration, Heart Rate, Stress Level,...
- Phân tích mối quan hệ giữa các đặc trưng và biến mục tiêu Sleep Disorder.
- Kiểm tra sự mất cân bằng của nhãn (Sleep Disorder), từ đó lên kế hoạch xử lý bằng kỹ thuật cân bằng dữ liệu.

Tiền xử lý dữ liệu

- Xử lý dữ liệu theo ngữ cảnh
- Tách cột huyết áp
- Chia tập huấn luyện và kiểm tra trước khi xử lý dữ liệu
- Xử lý giá trị, xử lý đặc trưng để giảm độ phức tạp bài toán
- Mã hóa biến phân loại
- Xử lý mất cân bằng dữ liệu

Lựa chọn và huấn luyện mô hình

Hai thuật toán được lựa chọn để huấn luyện và đánh giá:

- Random Forest Classifier
- Support Vector Machine (SVM)

Đánh giá và so sánh mô hình

- Đánh giá với tiêu chí đánh giá được đặt ra, so sánh và chọn ra mô hình được đánh giá tốt nhất.

1.4 Vai trò của khai phá dữ liệu trong việc giải quyết bài toán trên

Khai phá dữ liệu (Data Mining) đóng vai trò trung tâm trong việc giải quyết bài toán phân loại rối loạn giấc ngủ. Với sự phát triển mạnh mẽ của dữ liệu về sức khỏe cá nhân và lối sống, việc áp dụng các kỹ thuật khai phá dữ liệu giúp phát hiện ra các mẫu tiềm ẩn và mối quan hệ có ý nghĩa giữa các yếu tố ảnh hưởng đến chất lượng giấc ngủ

Dữ liệu thu thập từ nhiều cá nhân bao gồm cả yếu tố sinh lý, hành vi và cảm xúc (stress, hoạt động thể chất, nhịp tim, BMI, nghề nghiệp, v.v.). Các mối quan hệ giữa các yếu tố này với tình trạng rối loạn giấc ngủ không thể hiện một cách rõ ràng nếu chỉ quan sát thông thường. Người phân tích có thể tìm thấy những điểm bất thường, xu hướng hoặc nhóm hành vi nguy cơ cao dẫn đến các dạng rối loạn giấc ngủ.

Biến đổi dữ liệu thô ban đầu thành tập dữ liệu có cấu trúc phù hợp để huấn luyện mô hình. Nhờ đó, mô hình có khả năng học được các quy luật và xu hướng mà con người khó phát hiện thủ công.

Khai phá dữ liệu không chỉ là bước trung gian mà là **nền tảng quan trọng** trong toàn bộ chu trình phân tích – từ tiền xử lý, trực quan hóa đến huấn luyện mô hình và đưa ra dự đoán. Nhờ khai phá dữ liệu, bài toán được định hình rõ ràng hơn, mô hình học được tốt hơn, và kết quả đầu ra trở nên tin cậy và có giá trị ứng dụng cao.

1.5 Kết quả dự đoán sau khi giải quyết bài toán trên

Sau khi áp dụng các thuật toán học máy như Random Forest và Support Vector Machine (SVM) để phân loại tình trạng rối loạn giấc ngủ, mô hình thu được kết quả dự đoán với độ chính xác khá cao.

Thuật toán Random Forest cho hiệu suất tốt nhất, đạt độ chính xác từ 0.93 đến 0.95 và F1-score cao trên cả ba lớp: Không rối loạn, Mất ngủ, và Ngưng thở khi ngủ. SVM cũng đạt kết quả ổn định nhưng độ chính xác thấp hơn đôi chút và phụ thuộc nhiều vào bước chuẩn hóa dữ liệu.

Việc đánh giá mô hình không chỉ dựa vào độ chính xác (Accuracy) mà còn sử dụng các chỉ số khác như F1-score, ma trận nhầm lẫn (Confusion Matrix) và kỹ thuật Cross-validation để đảm bảo độ tin cậy và khả năng tổng quát của mô hình.

Từ kết quả này, mô hình có thể ứng dụng thực tế trong việc hỗ trợ phát hiện sớm rối loạn giấc ngủ, tư vấn cải thiện lối sống, tích hợp vào các ứng dụng sức khỏe và phục vụ nghiên cứu cộng đồng. Ngoài ra, mô hình có tiềm năng mở rộng khi kết hợp với dữ liệu từ thiết bị đeo hoặc dữ liệu y tế chi tiết hơn nhằm nâng cao độ chính xác dự đoán.

Chương 2: MÔ TẢ DỮ LIỆU

2.1 Kích thước dữ liệu, chiều dữ liệu, trích dẫn nguồn dữ liệu

- Bộ dữ liệu được trích xuất từ nguồn công khai có trên Kaggle:

Sleep Health and Lifestyle Dataset

Tác giả: Adewunmi Oladipupo

Đường dẫn:

<https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>

Trong đó:

Số dòng (samples): 374

Số cột (thuộc tính + nhãn): 13

Dữ liệu có sự pha trộn giữa **dữ liệu định lượng (số)** và **dữ liệu định tính (chuỗi)**. Điều này đòi hỏi phải xử lý mã hóa (encoding) phù hợp trước khi đưa vào mô hình học máy.

Bộ dữ liệu này được xây dựng nhằm hỗ trợ phân tích và nghiên cứu mối quan hệ giữa sức khỏe thể chất, lối sống và chất lượng giấc ngủ. Nó rất phù hợp để áp dụng các kỹ thuật khai phá dữ liệu và học máy để phân loại hoặc phát hiện bất thường trong giấc ngủ.

2.2 Các kiểu dữ liệu

STT	Tên thuộc tính	Mô tả	Kiểu dữ liệu
1	Person ID	Mã định danh của từng cá nhân	object
2	Gender	Giới tính của cá nhân	object
3	Age	Tuổi	int64
4	Occupation	Nghề nghiệp	object
5	Sleep Duration	Thời gian ngủ trung bình mỗi đêm (giờ)	float64
6	Quality of Sleep	Chất lượng giấc ngủ (thang điểm 1–10)	int64
7	Physical Activity Level	Mức độ hoạt động thể chất (điểm, từ 30 đến 100)	int64
8	Stress Level	Mức độ căng thẳng (thang điểm 1–10)	int64
9	BMI Category	Phân loại chỉ số BMI	object
10	Heart Rate	Nhịp tim trung bình (bpm)	int64
11	Daily Steps	Số bước đi trung bình mỗi ngày	int64
12	Systolic	Huyết áp tâm thu (mmHg)	int64
13	Diastolic	Huyết áp tâm trương (mmHg)	int64
14	Sleep Disorder	Loại rối loạn giấc ngủ	object


Bảng 2.1 Bảng mô tả các thuộc tính dữ liệu

Lưu ý:


- ✧ Thuộc tính Blood Pressure đã được tách thành hai cột riêng biệt là Systolic và Diastolic. Từ đó số cột sẽ được cập nhật từ 13 cột lên 14 cột.

- ✧ Sleep Disorder sau tiền xử lý sẽ được mã hóa nhãn với mục đích mô hình sẽ học dễ dàng hơn. Lần lượt ['None' 'Sleep Apnea' 'Insomnia'] là [1 2 0]


2.3 Thống kê mô tả về dữ liệu




Hình 2.1 Thống kê số phút bệnh nhân hoạt động thể chất mỗi ngày




Hình 2.2 Thống kê mức độ căng thẳng của bệnh nhân




Hình 2.3 Thống kê tuổi của bệnh nhân




Hình 2.4 Thống kê số giờ bệnh nhân ngủ mỗi ngày




Hình 2.5 Thống kê nhịp tim của bệnh nhân




Hình 2.6 Thống kê số bước chân bệnh nhân đi mỗi ngày




Hình 2.7 Thống kê huyết áp tâm thu của bệnh nhân




Hình 2.8 Thống kê huyết áp tâm trương của bệnh nhân




Hình 2.9 Thống kê bệnh nhân mắc bệnh rối loạn giấc ngủ (dương tính)



Hình 2.10 Thống kê chỉ số BMI của bệnh nhân



Hình 2.11 Thống kê giới tính của bệnh nhân



Hình 2.12 Thống kê nghề nghiệp của bệnh nhân

2.4 Những giả thiết khi thu thập dữ liệu.

- **Giấc ngủ và sức khỏe chịu ảnh hưởng bởi các yếu tố đo lường được.**

Các yếu tố như **stress, caffeine, hoạt động thể chất, nhịp tim, huyết áp** có liên quan chặt chẽ đến chất lượng giấc ngủ. Do đó, dữ liệu thu thập tập trung vào các đặc trưng này, bỏ qua các yếu tố không đo lường được như yếu tố di truyền, tâm lý sâu xa, hoặc môi trường xã hội.

- **Dữ liệu được khai báo đúng và trung thực.**

Người tham gia trả lời trung thực và chính xác về thời gian ngủ, mức tiêu thụ caffeine, mức độ stress,... Tuy nhiên, đây là các đặc trưng mang tính chủ quan, dễ bị ảnh hưởng bởi cảm xúc hoặc trí nhớ nên tiềm ẩn sai số báo cáo.

- **Dữ liệu được thu thập từ một cộng đồng mẫu đại diện.**

Ngầm hiểu rằng **tập dữ liệu phản ánh đúng phân bố của dân số chung**, dù thực tế có thể chỉ là một mẫu ngẫu nhiên từ nhóm nghề nghiệp cụ thể (như nhân viên y tế, kỹ sư...). Điều này có thể gây **thiên lệch (bias)** nếu dùng dữ liệu để tổng quát cho toàn bộ dân số.

- **Các thuộc tính đo được là độc lập và không gây nhiễu lẫn nhau.**

Dữ liệu coi **caffeine và stress là hai yếu tố độc lập**, trong khi thực tế có thể tồn tại mối liên hệ giữa **caffeine cao → khó ngủ → stress**. Sự đơn giản hóa mối quan hệ giữa các đặc trưng là giả định giúp mô hình hóa dễ dàng hơn.

- **Thông tin về rối loạn giấc ngủ là chính xác và đã được chẩn đoán.**

Một số cá nhân được gắn nhãn như “Insomnia” hay “Sleep Apnea” được cho là đã qua chẩn đoán lâm sàng, tuy nhiên điều này **không được xác minh trong tập dữ liệu**. Có khả năng nhãn này dựa vào **tự báo cáo (self-report)** thay vì khám chuyên sâu.

Chương 3: PHƯƠNG PHÁP KHAI PHÁ DỮ LIỆU

3.1 Quy trình khai phá dữ liệu

Quy trình khai phá dữ liệu gồm **10 bước** cơ bản như sau:

Bước 1: Nghiên cứu lĩnh vực

- Trước khi tiến hành khai phá dữ liệu, nhóm đã tìm hiểu về **lĩnh vực sức khỏe giấc ngủ**, một chủ đề ngày càng được quan tâm trong đời sống hiện đại. Việc xác định các yếu tố ảnh hưởng đến giấc ngủ như thời lượng ngủ, mức độ căng thẳng, hoạt động thể chất,... giúp định hướng rõ mục tiêu khai phá: **dự đoán rối loạn giấc ngủ của một người dựa trên các đặc trưng sức khỏe và lối sống**.

Bước 2: Tạo tập tin dữ liệu đầu vào

- Nguồn dữ liệu được sử dụng là tập dữ liệu **Sleep Health and Lifestyle Dataset**, bao gồm **374 mẫu** với **13 thuộc tính**. Dữ liệu được lưu trữ ở định dạng .csv, dễ dàng đọc và xử lý bằng công cụ Python. Các cột dữ liệu bao gồm thông tin cá nhân (tuổi, giới tính, nghề nghiệp), lối sống (số bước đi, mức độ hoạt động), sức khỏe (nhịp tim, huyết áp, BMI) và giấc ngủ (chất lượng, thời lượng, mức độ stress).

Bước 3: Tiền xử lý, làm sạch, mã hóa

- Dữ liệu sau khi tải về được tiền xử lý như sau:

Xử lý các giá trị, ngữ cảnh không phù hợp.

Các cột dạng chuỗi như Gender, Occupation, BMI Category, Sleep Disorder được mã hóa bằng kỹ thuật phù hợp (Label Encoding hoặc One-hot Encoding).

Các giá trị số được **chuẩn hóa** để đưa về cùng thang đo, thuận tiện cho các mô hình học máy như SVM.

Một số đặc trưng như Blood Pressure dạng chuỗi "120/80" có thể cần được tách thành 2 cột (tâm thu, tâm trương) nếu khai thác chi tiết hơn.

Bước 4: Rút gọn chiều dữ liệu

- Dữ liệu gốc có số chiều vừa phải nên không sử dụng kỹ thuật giảm chiều phức tạp như PCA hay Rough Set. Tuy nhiên, việc mã hóa biến và chọn lọc đặc trưng đầu vào chính là một hình thức gián tiếp giúp rút gọn chiều dữ liệu, giảm nhiễu cho mô hình. Ngoài ra, một số cột ít liên quan hoặc trùng lặp thông tin có thể được loại bỏ trong quá trình thử nghiệm.

Bước 5: Chọn các đặc trưng khai thác dữ liệu

- Mục tiêu khai phá là **phân lớp (classification)**, cụ thể là phân loại một cá nhân vào một trong ba loại rối loạn giấc ngủ: None, Insomnia, hoặc Sleep Apnea.

- Do đó, các đặc trưng được khai thác tập trung vào:

Các đặc trưng định lượng: Sleep Duration, Stress Level, Physical Activity Level, Quality of Sleep, Heart Rate, Daily Steps

Các đặc trưng phân loại: Gender, Occupation, BMI Category

Bước 6: Chọn các thuật giải khai thác dữ liệu

- Hai thuật toán học máy được lựa chọn cho bài toán phân loại đa lớp là:

Random Forest: Một mô hình học tổ hợp mạnh, hoạt động tốt với dữ liệu phức tạp và hỗn hợp nhiều loại đặc trưng.

Support Vector Machine (SVM): Hiệu quả cao với dữ liệu có độ phân tách rõ, đặc biệt khi đã chuẩn hóa.

Bước 7: Khai thác dữ liệu – Tìm kiếm tri thức

- Ở bước này, dữ liệu được chia thành **tập huấn luyện và kiểm tra** sau đó trải qua tiền xử lý, đã được dọn và xử lý xong. Hai mô hình (Random Forest và SVM) được huấn luyện bằng tập huấn luyện. Sau đó, dự đoán nhãn Sleep Disorder được thực hiện trên tập kiểm tra. Việc điều chỉnh siêu tham số và đánh giá chéo giúp tìm ra mô hình có hiệu suất tốt nhất.

Bước 8: Đánh giá mẫu tìm được

- Kết quả dự đoán được so sánh với nhãn thực tế để tính toán:

Độ chính xác (Accuracy)

Độ chính xác dương tính (Precision)

Độ nhạy (Recall)

F1-score

- Dựa trên các chỉ số này, nhóm có thể đánh giá mô hình nào hoạt động hiệu quả hơn, cũng như hiểu rõ điểm mạnh/yếu của từng mô hình với các loại rối loạn giấc ngủ khác nhau.

Bước 9: Biểu diễn tri thức

- Kết quả khai phá được trình bày thông qua:

- ✧ **Biểu đồ cột, biểu đồ phân tán, ma trận nhầm lẫn,...**
- ✧ Các bảng thống kê tổng hợp giúp người đọc hiểu được mức độ chính xác và khả năng phân biệt của từng mô hình.
- ✧ Các trực quan hóa được thực hiện bằng thư viện như matplotlib, seaborn trong Python.

Bước 10: Sử dụng các tri thức vừa khám phá

- Tri thức thu được có thể ứng dụng vào nhiều mục đích:

- ✧ Hỗ trợ chuyên gia y tế trong việc **phát hiện sớm rối loạn giấc ngủ**.
- ✧ Gợi ý cải thiện lối sống (tăng cường vận động, giảm stress) để nâng cao chất lượng giấc ngủ.
- ✧ Là nền tảng cho việc phát triển các hệ thống khuyến nghị sức khỏe thông minh trong tương lai.

3.2. Nguyên lý hoạt động của mô hình/thuật toán

– Random Forest

Random Forest là một **thuật toán học máy tổ hợp (ensemble learning)**, thuộc nhóm **Bagging**, được xây dựng từ nhiều cây quyết định (Decision Tree).

Cách hoạt động của Random Forest gồm các bước:

- ❖ **Huấn luyện nhiều cây quyết định** trên các tập con ngẫu nhiên của dữ liệu huấn luyện. Mỗi cây học trên một phần khác nhau của dữ liệu, giúp giảm thiểu hiện tượng overfitting.
- ❖ Tại mỗi node của cây, **một tập con ngẫu nhiên các đặc trưng** được chọn để tìm ra tiêu chí phân chia tốt nhất thay vì xét toàn bộ đặc trưng như cây quyết định thông thường.
- ❖ Khi dự đoán, các cây sẽ bỏ phiếu (voting) và kết quả được xác định bằng **đa số phiếu** (đối với phân loại).

Ưu điểm:

- ✧ Hoạt động tốt với dữ liệu chứa nhiều đặc trưng và kiểu dữ liệu khác nhau (số, phân loại).
- ✧ Giảm hiện tượng overfitting do sử dụng trung bình nhiều cây.
- ✧ Có thể ước lượng mức độ quan trọng của từng đặc trưng.

Nhược điểm:

- ✧ Thời gian huấn luyện có thể lâu với số lượng cây lớn.
- ✧ Khó giải thích rõ ràng hơn so với mô hình tuyến tính.

– Support Vector Machine (SVM)

SVM là một mô hình học có giám sát, được sử dụng chủ yếu cho **bài toán phân loại nhị phân**, nhưng cũng có thể mở rộng cho phân loại đa lớp.

Nguyên lý chính:

- ❖ Tìm **siêu phẳng (hyperplane)** tối ưu để phân tách các điểm dữ liệu thuộc các lớp khác nhau, sao cho **khoảng cách (margin)** từ siêu phẳng đến các điểm gần nhất của mỗi lớp là **lớn nhất**.
- ❖ Với dữ liệu **không tuyến tính**, SVM sử dụng **hàm kernel** (như RBF, polynomial) để ánh xạ dữ liệu vào không gian chiều cao hơn, nơi có thể tìm được siêu phẳng phân chia tuyến tính.

- ❖ Khi phân loại, SVM xác định xem điểm mới thuộc phía nào của siêu phẳng.

Ưu điểm:

- ✧ Có hiệu suất tốt trong các bài toán phân loại phức tạp với không gian đặc trưng lớn.
- ✧ Khả năng tổng quát hóa cao với dữ liệu nhỏ hoặc trung bình.
- ✧ Hữu ích với dữ liệu đã được chuẩn hóa.

Nhược điểm:

- ✧ Cần chọn kernel và điều chỉnh siêu tham số cẩn thận.
- ✧ Tốc độ huấn luyện chậm với dữ liệu lớn.
- ✧ Khó giải thích mô hình so với cây quyết định.

3.3. Cách cài đặt mô hình

– Random Forest

Bước 1: Chuẩn bị dữ liệu

- Lấy dữ liệu đã qua tiền xử lý và dọn sạch. Đầu vào X là các thuộc tính/đặc trưng mà mô hình sẽ dự đoán, Y là thuộc tính mục tiêu, có thể nói là kết quả dự đoán.

Bước 2: Xây dựng mô hình Random Forest

- **Không cần chuẩn hóa dữ liệu**, vì Random Forest không bị ảnh hưởng bởi quy mô giá trị của đặc trưng.
- Mô hình sử dụng là `RandomForestClassifier()` từ thư viện `sklearn.ensemble`.
- Nguyên lý: Random Forest xây dựng nhiều cây quyết định trên các tập con khác nhau của dữ liệu huấn luyện, rồi thực hiện biểu quyết (voting) kết quả.
- Đầu vào là **X_{train}** (ma trận các đặc trưng) và **y_{train}** (nhãn tương ứng).
- Mỗi cây trong rừng chỉ nhìn thấy một phần dữ liệu (bagging), từ đó giảm overfitting.

Bước 3: Huấn luyện mô hình

- Gọi hàm `fit(X_train, y_train)` để mô hình học mối quan hệ giữa X và Y .
- Trong quá trình học, mỗi cây học cách phân chia không gian đặc trưng dựa trên tiêu chí như **Gini impurity** hoặc **Entropy**.

Bước 4: Dự đoán

- Dữ liệu kiểm tra X_{test} được đưa vào mô hình bằng hàm `predict(X_test)`, trả về tập nhãn dự đoán **y_{pred}** .
- Mỗi cây trong rừng dự đoán một nhãn, và kết quả cuối cùng là nhãn được bỏ phiếu nhiều nhất.

– SVM (Support Vector Machine)

Bước 1: Chuẩn bị dữ liệu

- Tương tự với bước 1 của Random Forest

Bước 2: Xây dựng mô hình SVM

- Tuy nhiên, với SVM, dữ liệu **phải được chuẩn hóa** do mô hình này sử dụng khoảng cách để phân chia lớp.
- Sử dụng `StandardScaler()` để đưa các đặc trưng X về cùng thang đo ($\text{mean} = 0, \text{std} = 1$).
- Sử dụng `SVC()` từ `sklearn.svm`.
- SVM hoạt động bằng cách tìm siêu phẳng (hyperplane) tối ưu phân chia các lớp.
- Với dữ liệu không tuyến tính, kernel (nhân) như `rbf` được dùng để ánh xạ dữ liệu sang không gian mới.
- Các siêu tham số chính:
- **C**: điều chỉnh giữa độ chính xác trên train và mức độ đơn giản của siêu phẳng.
- **gamma**: kiểm soát mức ảnh hưởng của từng điểm huấn luyện.

Bước 3: Huấn luyện mô hình

- Gọi `fit(X_train, y_train)` để tìm siêu phẳng phân loại tối ưu.
- Mỗi điểm dữ liệu trong tập train có dạng vector đặc trưng $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$, nhãn $y \in \{0, 1\}$.
- SVM tối ưu hàm mất mát để tìm ra hyperplane có khoảng cách lớn nhất đến các điểm gần ranh giới nhất (support vectors).

Bước 4: Dự đoán

- Sử dụng `predict(X_test)` để dự đoán nhãn cho dữ liệu kiểm tra.
- Dự đoán dựa trên phía nào của siêu phẳng mà điểm nằm ở.

3.4. Tiêu chí đánh giá mô hình

- Các tiêu chí đánh giá được sử dụng bao gồm:

Accuracy (Độ chính xác)

- Là tỷ lệ số lượng dự đoán đúng trên tổng số dự đoán.
- Công thức:

$$\text{Accuracy} = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}}$$

Hoặc

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- Tuy nhiên, trong các bài toán mất cân bằng nhãn, accuracy có thể gây hiểu nhầm nếu mô hình chỉ học tốt nhãn chiếm số đông.

Precision (Độ chính xác của dự đoán dương)

- Là tỷ lệ giữa số dự đoán dương đúng (true positives) trên tổng số dự đoán là dương (true positives + false positives).
- Phản ánh khả năng mô hình tránh báo động giả.
- Công thức:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall (Độ nhạy)

- Là tỷ lệ số dự đoán dương đúng trên tổng số thực tế là dương (true positives + false negatives).
- Phản ánh khả năng phát hiện đúng các trường hợp dương tính thực sự.
- Công thức:

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-score

- Là trung bình điều hòa giữa Precision và Recall, dùng để cân bằng cả hai yếu tố.
- Phù hợp trong các bài toán phân loại mất cân bằng.
- Công thức:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

AUC (Area Under Curve)

- Là diện tích dưới đường cong ROC.
- Chỉ số này đo lường khả năng phân biệt giữa các lớp.
- Giá trị AUC càng gần 1 thì mô hình càng tốt.

Chương 4: THỰC NGHIỆM

4.1. Yêu cầu về chương trình

Ngôn ngữ lập trình:

- Python phiên bản **3.10.12**
- Công cụ sử dụng:
 - ✓ **Google Colab:**

Là nền tảng chạy notebook Python trực tuyến do Google cung cấp.

Cho phép sử dụng tài nguyên tính toán (CPU, RAM) trên cloud miễn phí.

Không cần cài đặt môi trường thủ công, dễ dàng chia sẻ và lưu trữ trên Google Drive.

Ngoài ra, có thể sử dụng các công cụ khác như:

- ✓ **Jupyter Notebook.**
- ✓ **VS Code (dạng .ipynb).**

Các thư viện sử dụng:

Tên thư viện	Phiên bản	Chức năng chính
pandas	1.5.3	Xử lý dữ liệu dạng bảng
numpy	1.22.4	Xử lý số học, mảng đa chiều
matplotlib	3.7.1	Trực quan hóa dữ liệu
seaborn	0.12.2	Trực quan hóa dữ liệu nâng cao
scikit-learn	1.2.2	Xây dựng và đánh giá mô hình học máy
joblib	1.2.0	Lưu và tải mô hình đã huấn luyện

Bảng 4.1 Thư viện sử dụng

Cấu hình máy tính:

- ❖ **Hệ điều hành:** Không cần thiết vì sử dụng Google Colab
- ❖ **CPU:** Intel Core i5 hoặc tương đương
- ❖ **RAM:** 8 GB
- ❖ **Bộ nhớ:** ít nhất 1 GB dung lượng trống.

4.2 Thực hiện khai phá dữ liệu

Bước 1: Chuẩn bị dữ liệu

- **Xử lý dữ liệu theo ngữ cảnh:** Các cột không mang thông tin hữu ích hoặc gây nhiễu (ví dụ ID, địa chỉ email...) được loại bỏ. Kiểm tra tính hợp lý giữa các đặc trưng như thời gian ngủ, chỉ số sinh học để tránh mâu thuẫn.
- **Chia dữ liệu:** Dữ liệu được chia thành:
 - Tập huấn luyện (Training set): 60%**
 - Tập kiểm tra (Testing set): 40%**
- **Xử lý giá trị:**
 - **Giá trị thiếu:** Kiểm tra các giá trị bị thiếu (NaN) trong từng cột. Với các cột số, sử dụng **giá trị trung bình** hoặc **trung vị** để điền vào.
 - Loại bỏ các mẫu trùng lặp.
- **Xử lý đặc trưng:**
 - Loại bỏ các đặc trưng có quan hệ tương quan cao (trên 0.8)
 - Các cột dạng phân loại được mã hóa lại bằng hai kỹ thuật:
 - One-Hot Encoding:** áp dụng cho các cột như 'Gender', 'Occupation', 'BMI Category',... để chuyển thành vector nhị phân.
 - Label Encoding:** áp dụng cho cột mục tiêu '**Sleep Disorder**', chuyển các giá trị rối loạn giấc ngủ thành số nguyên để phục vụ cho mô hình phân loại.
- **Cân bằng lớp (Class Balancing):**

Sử dụng kỹ thuật **SMOTE (Synthetic Minority Oversampling Technique)** để cân bằng lại số lượng các lớp (Insomnia, Sleep Apnea, None), tránh mô hình thiên lệch do mất cân bằng nhãn.

Bước 2: Xây dựng mô hình và pipeline

Dữ liệu sau khi xử lý được sử dụng để huấn luyện hai mô hình khác nhau:

- ◆ **Random Forest Classifier:** Huấn luyện trực tiếp trên dữ liệu đã xử lý, **không sử dụng chuẩn hóa đặc trưng**.
- ◆ **SVM (Support Vector Machine):** Do SVM yêu cầu dữ liệu có cùng tỷ lệ, mô hình này được huấn luyện thông qua **Pipeline**, bao gồm:
 - **StandardScaler:** Chuẩn hóa các đặc trưng số.
 - **SVM classifier:** Thuật toán SVM với kernel mặc định (thường là RBF hoặc linear).

Bước 3: Huấn luyện mô hình

Thực hiện huấn luyện cả hai mô hình trên tập $X_{\text{train}}, y_{\text{train}}$:

Đối với Random Forest, mô hình được huấn luyện trực tiếp.

Đối với SVM, Pipeline gồm chuẩn hóa và phân loại được áp dụng trước khi học.

Bước 4: Dự đoán, so sánh và đánh giá

- Sau khi huấn luyện, mô hình được sử dụng để dự đoán trên X_{test} .
- Đánh giá hiệu suất mô hình qua các chỉ số:
 - ✧ **Accuracy (Độ chính xác)**
 - ✧ **Precision, Recall, F1-score**
 - ✧ **Ma trận nhầm lẫn (Confusion Matrix)**
 - ✧ **ROC_AUC (Đánh giá hiệu suất phân loại các lớp)**

Bước 5: Dự đoán với dữ liệu mới

- Chọn ngẫu nhiên một dòng dữ liệu trong X_test , thực hiện dự đoán với mô hình tốt nhất.
- So sánh với nhãn thực tế trong y_test để thấy độ **dự đoán chính xác** của mô hình.

4.3. Code

```
df = pd.read_csv('sleep_health_and_lifestyle_dataset.csv')
df[['Systolic', 'Diastolic']] = df['Blood Pressure'].str.split('/', expand=True).astype(np.float64)
df = df.drop(columns=['Blood Pressure']) # Vì đã tách Systolic và Diastolic nên bỏ đi Blood Pressure

cols = list(df.columns)
cols.remove('Sleep Disorder')
cols.append('Sleep Disorder')
df = df[cols]
df
```

Hình 4.1 Đọc dữ liệu gốc và tách thuộc tính Blood Pressure

▼ Tiền xử lý dữ liệu

▼ Xử lý dữ liệu theo ngữ cảnh

```
[ ] # Điền các NaN trong cột 'Sleep Disorder' thành None cho đúng với bản gốc
df['Sleep Disorder'] = df['Sleep Disorder'].fillna('None')

# Biến đổi giá trị ngữ cảnh Normal thành Normal Weight, Obese thành Overweight
df['BMI Category'] = df['BMI Category'].replace({'Normal': 'Normal Weight', 'Obese': 'Overweight'})
```

▼ Chia dữ liệu

Chia dữ liệu trước khi xử lý dữ liệu để đảm bảo tập test vẫn giữ bản chất

```
[ ] from sklearn.model_selection import train_test_split

X = df.drop(columns=['Sleep Disorder'])
y = df['Sleep Disorder']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.4, random_state=42)

# Nối X_train và y_train lại với nhau thành 1 tập train, tương tự với tập test
df = pd.concat([X_train, y_train], axis=1)
test_df = pd.concat([X_test, y_test], axis=1)
```

Hình 4.2 Xử lý ngữ cảnh và chia dữ liệu

▼ Xử lý giá trị

```
[ ] from sklearn.impute import SimpleImputer

# Xác định các cột numeric và categorical
numeric_cols = df.select_dtypes(include=['float64', 'int64']).columns
categorical_cols = df.select_dtypes(include=['object']).columns

# Imputation cho biến numeric: sử dụng trung vị
num_imputer = SimpleImputer(strategy='median')
df[numeric_cols] = num_imputer.fit_transform(df[numeric_cols])
test_df[numeric_cols] = num_imputer.transform(test_df[numeric_cols])

# Imputation cho biến categorical: sử dụng giá trị mode
cat_imputer = SimpleImputer(strategy='most_frequent')
df[categorical_cols] = cat_imputer.fit_transform(df[categorical_cols])
test_df[categorical_cols] = cat_imputer.transform(test_df[categorical_cols])

# Loại bỏ các đối tượng trùng lặp
df.drop_duplicates(inplace=True)
```

Hình 4.3 Xử lý giá trị

▼ Xử lý đặc trưng

```
[ ] # Loại bỏ đặc trưng không quan trọng
df = df.drop(columns=['Person ID'])
test_df = test_df.drop(columns=['Person ID'])

# Chọn ra các cột số
numerical_df = df.select_dtypes(include=['number'])

# Tính toán ma trận tương quan
correlation_matrix = numerical_df.corr()

# Hiển thị ma trận tương quan bằng Seaborn
plt.figure(figsize=(12, 10))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f")
plt.title('Ma trận tương quan')
plt.show()

[ ] # Lấy danh sách các thuộc tính có độ tương quan cao hơn 0.8, trừ Systolic và Diastolic
highly_correlated_features = set()
for i in range(len(correlation_matrix.columns)):
    for j in range(i):
        # Kiểm tra điều kiện độ tương quan và loại trừ Systolic, Diastolic
        if abs(correlation_matrix.iloc[i, j]) > 0.8 and correlation_matrix.columns[i] not in ('Systolic', 'Diastolic') and correlation_matrix.c
            colname = correlation_matrix.columns[i]
            highly_correlated_features.add(colname)

# Loại bỏ các thuộc tính khỏi DataFrame (trừ Systolic và Diastolic)
df = df.drop(columns=highly_correlated_features)
test_df = test_df.drop(columns=highly_correlated_features)
print(f'Đã loại bỏ thuộc tính: {highly_correlated_features}')
```

Hình 4.4 + 4.5 Xử lý đặc trưng/ thuộc tính

▼ One-Hot Encoding

```
[ ] from sklearn.preprocessing import OneHotEncoder

categorical_cols = ['Gender', 'Occupation', 'BMI Category'] # Ngoài trừ Sleep Disorder
encoder = OneHotEncoder(sparse_output=False, handle_unknown='ignore')

# Reset index before one-hot encoding
df = df.reset_index(drop=True)
test_df = test_df.reset_index(drop=True)

encoded_data = encoder.fit_transform(df[categorical_cols])
encoded_test_data = encoder.transform(test_df[categorical_cols])
encoded_df = pd.DataFrame(encoded_data, columns=encoder.get_feature_names_out(categorical_cols)) # Tạo các columns cho encoded value với tên co
encoded_test_df = pd.DataFrame(encoded_test_data, columns=encoder.get_feature_names_out(categorical_cols))

# Nối lại df
final_df = pd.concat([df, encoded_df], axis=1)
final_test_df = pd.concat([test_df, encoded_test_df], axis=1)
final_df = final_df.drop(columns=categorical_cols) # Loại bỏ các cột cũ
final_test_df = final_test_df.drop(columns=categorical_cols)

# Lưu encoder.pkl
joblib.dump(encoder, 'encoder.pkl')
```

Hình 4.6 Mã hóa đặc trưng categorical

```

Label Encoding

[ ] from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
final_df['Sleep Disorder encoded'] = le.fit_transform(final_df['Sleep Disorder'])
final_test_df['Sleep Disorder encoded'] = le.transform(final_test_df['Sleep Disorder'])
final_df = final_df.drop(columns=['Sleep Disorder'])
final_test_df = final_test_df.drop(columns=['Sleep Disorder'])

# Lưu label Encoding
joblib.dump(le, 'label_encoder.pkl')

[ ] final_df.to_csv('final_df.csv', index=False)
final_test_df.to_csv('final_test_df.csv', index=False)

[ ] X_train = final_df.drop(columns=['Sleep Disorder encoded'])
y_train = final_df['Sleep Disorder encoded']
X_test = final_test_df.drop(columns=['Sleep Disorder encoded'])
y_test = final_test_df['Sleep Disorder encoded']

```

Hình 4.7 Mã hóa nhãn

```

Cân bằng lớp

from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=42, sampling_strategy="auto")
X_train, y_train = smote.fit_resample(X_train, y_train)

```

Hình 4.8 Cân bằng lớp SMOTE

```

RandomForest

[ ] from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

[ ] from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint

model = Pipeline([
    ("rf", RandomForestClassifier(random_state=42))
])

# Huấn luyện với tập dữ liệu của bạn
rf = model.fit(X_train, y_train)

SVM

[ ] from sklearn.svm import SVC
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import uniform, randint
from sklearn.multiclass import OneVsRestClassifier

model = Pipeline([
    ("scaler", StandardScaler()),
    ("svm", OneVsRestClassifier(SVC(kernel = 'rbf', probability=True, random_state=42)))
])

svm = model.fit(X_train, y_train)

```

Hình 4.9 Tạo mô hình và huấn luyện

Chương 5: KẾT QUẢ

5.1 Kết quả khai phá dữ liệu

5.1.1 Dựa trên tiêu chí đánh giá mô hình: Mô hình có chính xác hay không?

Dựa trên các chỉ số **Accuracy**, **F1-score**, và **ROC-AUC**, cả hai mô hình **Random Forest** và **SVM** đều đạt hiệu suất cao, tuy nhiên **Random Forest** cho thấy kết quả vượt trội hơn:

Random Forest:

Accuracy: **0.9067**

F1-score: **0.9067**

Cross-validation score: **0.9444**

ROC-AUC-OVR: Class 0 (**0.92**), Class 1 (**0.94**), Class 2 (**0.91**)

SVM:

Accuracy: **0.8867**

F1-score: **0.8867**

Cross-validation score: **0.9154**

ROC-AUC-OVR: Class 0 (**0.89**), Class 1 (**0.94**), Class 2 (**0.91**)

Cụ thể, mô hình **Random Forest** đạt độ chính xác cao hơn (90.67% so với 88.67%) và có khả năng tổng quát tốt hơn qua Cross-validation.

Ngoài ra, F1-score và AUC ở từng lớp cho thấy mô hình này cân bằng tốt giữa precision và recall cho cả ba lớp (0, 1, 2). Vì vậy, có thể khẳng định rằng **Random Forest** là mô hình chính xác và hiệu quả hơn.

5.1.2 Dựa trên tính giải thích được của mô hình (interpretability): Có thể giải thích tại sao mô hình ra kết quả chính xác được hay không?

Random Forest là một mô hình tổ hợp (ensemble) gồm nhiều cây quyết định, và mặc dù nó ít trực quan hơn so với một cây đơn lẻ, nhưng vẫn có thể giải thích được ở mức độ nhất định nhờ vào:

- **Feature Importance:** Random Forest cung cấp chỉ số tầm quan trọng của từng đặc trưng (feature importance scores). Điều này giúp ta hiểu được những yếu tố nào ảnh hưởng mạnh nhất đến quyết định phân loại.
- **Quy tắc phân tách** (splitting rules): Dù toàn bộ mô hình là tổ hợp phức tạp, mỗi cây con trong rừng vẫn dựa vào các điều kiện ngưỡng rõ ràng để phân loại. **Mỗi quyết định phân loại** được đưa ra bằng cách xét điều kiện phân nhánh (ví dụ: "nếu BMI > 25 và Glucose > 120 thì → class 1").

SVM, ngược lại, đặc biệt khi sử dụng kernel phi tuyến, khó giải thích hơn vì nó hoạt động dựa trên khái niệm siêu phẳng trong không gian đặc trưng cao chiều. Mô hình SVM **khó hiểu và không trực quan** đối với người không chuyên, nhất là khi không phải SVM tuyến tính.

- Không thể trực tiếp biết được tầm quan trọng của từng đặc trưng.
- Không thể biểu diễn quyết định phân loại bằng các điều kiện logic như Random Forest.
- Cách ánh xạ vào không gian đặc trưng cao chiều là "hộp đen", gây khó khăn trong việc lý giải.

Do đó, **Random Forest không chỉ chính xác hơn mà còn có khả năng giải thích cao hơn**, thích hợp cho các bài toán cần đánh giá lý do đằng sau các dự đoán của mô hình.

5.2 So sánh kết quả thực tế với kết quả dự đoán

5.2.1 Chất lượng của dữ liệu

Dữ liệu đầu vào đã trải qua quá trình tiền xử lý kỹ lưỡng nhằm đảm bảo độ chính xác cho quá trình huấn luyện mô hình:

- ✓ **Loại bỏ các đặc trưng không cần thiết:** Các cột như Stress Level, Quality of Sleep không xuất hiện trong tập dữ liệu cuối cùng, giúp tránh dư thừa và nhiễu thông tin.
- ✓ **Cân bằng dữ liệu:** Dữ liệu được cân bằng giữa ba lớp **Insomnia (0)**, **None (1)** và **Sleep Apnea (2)**, nhờ đó giúp mô hình không bị thiên lệch về lớp phổ biến.
- ✓ **Chuẩn hóa đặc trưng:** Đối với mô hình SVM, dữ liệu đã được chuẩn hóa bằng StandardScaler thông qua Pipeline – một yêu cầu quan trọng để thuật toán hoạt động hiệu quả trong không gian vector có kích thước cao.
- ✓ **Mã hóa dữ liệu phân loại:** Các biến phân loại như Occupation, BMI Category, Gender... đã được xử lý thích hợp để phù hợp với mô hình học máy.

Actual: 2, Predicted: 0	Actual: 2, Predicted: 0
Actual: 2, Predicted: 2	Actual: 2, Predicted: 1
Actual: 1, Predicted: 1	Actual: 1, Predicted: 1
Actual: 2, Predicted: 2	Actual: 2, Predicted: 2
Actual: 0, Predicted: 0	Actual: 0, Predicted: 0
Actual: 2, Predicted: 2	Actual: 2, Predicted: 2
Actual: 2, Predicted: 2	Actual: 2, Predicted: 2
Actual: 1, Predicted: 1	Actual: 1, Predicted: 1
Actual: 0, Predicted: 0	Actual: 0, Predicted: 0
Actual: 1, Predicted: 1	Actual: 1, Predicted: 1

Hình 5.1 + 5.2 Dự đoán (Predicted) so với nhãn thực tế (Actual)

Random Forest vs SVM

Dựa vào chỉ số Accuracy xét theo tiêu chí đánh giá từ Kết quả khai phá dữ liệu. Tỷ lệ chính xác phản ánh đúng với kết quả dự đoán ta thấy.

=> **Kết luận:** Dữ liệu đạt chất lượng tốt, không có giá trị thiếu, không bị mất cân bằng, và đã được chuẩn bị phù hợp với yêu cầu kỹ thuật của từng thuật toán. Điều này đã góp phần làm tăng độ chính xác dự đoán.

5.2.2 Nguyên lý hoạt động của thuật toán có giải quyết được vấn đề hay không?

Random Forest

- Random Forest sử dụng cơ chế tổ hợp nhiều cây quyết định, giúp mô hình trở nên mạnh mẽ và kháng nhiễu.
- Với bài toán phân loại rối loạn giấc ngủ, các đặc trưng như thời gian ngủ, nhịp tim, độ tuổi và chỉ số BMI có mối liên hệ phi tuyến với kết quả — điều này phù hợp với khả năng học mô hình phức tạp của Random Forest.
- Mô hình cho kết quả cao: **Accuracy = 0.9067, F1-score = 0.9067, Cross-validation = 0.9444**, cùng AUC trung bình trên 0.9 ở cả ba lớp => chứng tỏ khả năng phân biệt rõ ràng giữa các loại rối loạn.
- Cơ chế của Random Forest **rất phù hợp với bài toán này**, vì nó xử lý tốt dữ liệu không tuyến tính và có khả năng khái quát tốt nhờ voting giữa nhiều cây.

SVM (Support Vector Machine)

- SVM tìm siêu phẳng phân tách tối ưu giữa các lớp. Với hàm kernel phi tuyến (RBF), SVM có thể phân loại dữ liệu không tuyến tính.
- Tuy nhiên, hiệu suất của SVM phụ thuộc nhiều vào việc chuẩn hóa dữ liệu — điều đã được thực hiện thông qua Pipeline trong bài.
- Kết quả dự đoán cho thấy mô hình hoạt động tốt: **Accuracy = 0.8867, F1-score = 0.8867, Cross-validation = 0.9154**, và AUC trung bình cũng > 0.9.
- Tuy nhiên, trong confusion matrix, SVM **dự đoán nhầm nhiều hơn** ở lớp 0 và lớp 2 (Insomnia và Sleep Apnea) so với Random Forest.
- SVM **giải quyết được vấn đề**, nhưng mức độ hiệu quả thấp hơn Random Forest, đặc biệt là ở các lớp có đặc trưng dễ bị chồng lấn.

Chương 6: THẢO LUẬN VÀ KẾT LUẬN

6.1 Khả năng ứng dụng của giải pháp/mô hình

Giải pháp xây dựng mô hình dự đoán rối loạn giấc ngủ dựa trên các yếu tố sức khỏe và lối sống có tiềm năng ứng dụng rất cao trong các lĩnh vực:

- **Y tế dự phòng:** Hệ thống có thể tích hợp trong các ứng dụng theo dõi sức khỏe, hỗ trợ người dùng đánh giá nguy cơ rối loạn giấc ngủ chỉ bằng các chỉ số đơn giản như thời gian ngủ, nhịp tim, mức độ căng thẳng,...
- **Chăm sóc sức khỏe cá nhân:** Người dùng có thể biết được tình trạng giấc ngủ của bản thân một cách nhanh chóng và dễ hiểu mà không cần đến cơ sở y tế.
- **Hỗ trợ chuyên gia y tế:** Cung cấp thêm góc nhìn dữ liệu và phân tích cho bác sĩ để hỗ trợ quá trình chẩn đoán và điều trị.

Với mô hình Random Forest hoặc SVM đã được huấn luyện, hệ thống có thể triển khai dưới dạng ứng dụng web hoặc tích hợp trong đồng hồ/smartphone theo dõi sức khỏe.

6.2 Ưu điểm – Nhược điểm của giải pháp/mô hình

Tiêu chí	Ưu điểm	Nhược điểm
Tính chính xác	Cả hai mô hình đều đạt độ chính xác cao trên tập kiểm tra.	SVM dễ bị ảnh hưởng khi dữ liệu chưa chuẩn hóa.
Tính giải thích	Random Forest cung cấp chỉ số quan trọng (feature importance) rõ ràng.	SVM là mô hình khó giải thích, “hộp đen”.
Tốc độ huấn luyện	Cả hai mô hình đều huấn luyện khá nhanh do dữ liệu không lớn.	Với dữ liệu lớn hơn, Random Forest cần nhiều tài nguyên hơn.
Tính ứng dụng thực tế	Có thể triển khai API hoặc tích hợp app theo dõi sức khỏe.	Cần đảm bảo dữ liệu đầu vào được chuẩn hóa đúng định dạng.
Tính ổn định với nhiễu	Random Forest chống overfitting tốt.	SVM có thể nhạy với outlier nếu không xử lý kỹ.

Bảng 6.1 Bảng ưu điểm & Nhược điểm của giải pháp mô hình

6.3 Đề xuất

Dựa trên kết quả đã đạt được và tiềm năng ứng dụng, sẽ đề xuất một số hướng cải tiến và mở rộng trong tương lai như sau:

- **Tăng kích thước tập dữ liệu:** Thu thập thêm dữ liệu thực tế hoặc dữ liệu từ thiết bị đeo thông minh để tăng tính tổng quát cho mô hình.
- **Sử dụng các mô hình hiện đại hơn:** Thử nghiệm các mô hình như XGBoost, LightGBM hoặc mô hình học sâu (neural networks) để tăng độ chính xác và học tốt hơn các mối quan hệ phi tuyến.

- **Tích hợp phân tích theo thời gian:** Nếu có dữ liệu thời gian thực, có thể xây dựng mô hình theo dõi chất lượng giấc ngủ liên tục và phát hiện sớm các dấu hiệu bất thường.

TÀI LIỆU THAM KHẢO

- ❖ Aggarwal, C. C. (2015). *Data Mining: The Textbook*. Springer.
- ❖ Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- ❖ Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.
- ❖ Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- ❖ Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- ❖ Scikit-learn Developers. (2023). *scikit-learn: Machine Learning in Python*.
<https://scikit-learn.org/stable/>
- ❖ UCI Machine Learning Repository. Sleep Health and Lifestyle Dataset.
Retrieved from <https://www.kaggle.com/datasets/uom190346a/sleep-health-and-lifestyle-dataset>
- ❖ Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- ❖ Xu, Y., Goodacre, R. (2018). On Splitting Training and Validation Set: A Comparative Study of Cross-Validation, Bootstrap and Systematic Sampling for Estimating the Generalization Performance of Supervised Learning. *Journal of Analysis and Testing*, 2(3), 249–262.